Versión anteiror: 2014-11-21 Última actualización: 2015-06-24

Introducción

El catálogo de datos permite identificar los datos abiertos de una organización, describirlos, y hacerlos públicos en DATOS.GOB.MX.

Objetivos del catálogo

- **Descriptivo**: Capturar los metadatos mínimos requeridos de un conjunto de datos
 - Para mostrar descriptivamente una ficha bibliográfica en el catálogo de datos en http://catalogo.datos.gob.mx [ejemplo]
- **Extensibilidad**: permitir agregar campos adicionales para proveer información adicional al usuario.
- **Heterogeneidad**: ser agnóstico de formato (p.ej. XML, RDF, CSV).
- Recursos: permitir la descripción de archivos contenedores de los datos.
- **Estándar**: ser compatible con el estándar DCAT y DCT de metadatos para *datasets* de gobierno.

Glosario

DCAT: Es un vocabulario diseñado para facilitar la interoperabilidad entre catálogos de datos en la Web, utilizado por data.gov y data.gov.uk (entre otros).

Catálogo de datos: Un catálogo contiene conjuntos de datos (*datasets*) y recursos/descargables (*distributions*).

Conjunto de datos (*dataset*): Colección de datos, publicados o curados por un agente, y disponibles para acceso o descarga en uno o más formatos.

Escenarios

Hemos identificado una serie de escenarios en diferentes dependencias, sobre la manera en la que se publicarían y presentarían los *datasets* en DATOS.GOB.MX:

- 1. Los recursos (distributions)
 - a. tienen diferentes **formatos** [enlace]
 - b. son **series** de tiempo [enlace]
 - c. son **segmentos** filtrados [enlace]
 - d. requieren diccionario de datos único
- 2. Los **resultados de búsqueda se podrían llenar de ruido** enumerando mismos *datasets* con diferentes versiones del conjunto de datos, p. ej. fonden 2011, fonden 2012, fonden 2013; en lugar de simplemente "fonden", y tener como descargables 2011.csv, 2012.csv y 2013.csv.

3. Para **evitar llenar formularios**, como lo hizo data.gov¹, optamos por usar una tradicional hoja de cálculo [3] que automáticamente se transformará en DCAT.

Propuesta

Llenar la hoja de cálculo que sirve de plantilla para el catálogo de datos [enlace] llenando los metadatos acorde a lo que se presenta a continuación:

Metadatos (descriptores) del conjunto de datos (*dataset*)

ds:identifier	Identificador único del conjunto de datos. Utilizado para agrupar recursos dentro de un <i>dataset</i> , p. ej. "rezago-social", "unidades_medicas", "adquisiciones". Utilizar caracteres ASCII (sin acentos).
ds:title	Título descriptivo del conjunto de datos, p.ej. "Programa de fomento a la agricultura", "Vuelos comerciales".
ds:description	Una explicación de los datos, con suficiente detalle para que los usuarios puedan entender si es de su interés, p.ej. "Apoyos otorgados a través del programa Opciones Productivas, desglosado a nivel localidad".
ds:keyword	Lista de términos clave separados por coma, que facilitarán al usuario la búsqueda del conjunto de datos. Es importante considerar el uso de términos no técnicos. p.ej. "salud, medicinas, compras, agricultura".
ds:modified	Fecha y hora de la última modificación del conjunto de datos; en formato ISO 8601², p.ej. "2014-05-27T01:42:05-05:00"
ds:contactPoint	Nombre de la persona de contacto que atenderá dudas y comentarios sobre el conjunto de datos, p.ej. "Rodolfo Wilhelmy".
ds:mbox	Correo electrónico de contacto para atender dudas y comentarios sobre el conjunto de datos, p.ej. "rodolfo.wilhelmy@presidencia.gob.mx", "datos@presidencia.gob.mx".
ds:temporal	La fecha o fechas que cubren los datos, p.ej. "2013", "2010/2012", "2014-01/2014-04". Si es un rango de fechas, deberán ordenarse ascendentemente.

¹ http://project-open-data.github.io/catalog-generator/

² http://en.wikipedia.org/wiki/ISO 8601

ds:spatial	El espacio geográfico que cubre el conjunto de datos. Puede ser una región, el nombre de un lugar, una clave INEGI, un polígono o un cuadro delimitador de coordenadas geográficas (bounding box) en GML³. P.ej. "Baja California", 002, http://www.geonames.org/4017700/baja-california.html , "estatal", o "32.71,-112.32 27.99, -118.45".
ds:landingPage	Página web que puede ser navegada para acceder a información adicional que complemente el conjunto de datos, como pueden ser diccionario de datos, manuales, entre otros. El equivalente de este campo en la versión 2.0 del catálogo era ds:dataDictionary. A pesar de que estos campos pueden utilizarse con ambas etiquetas, se recomienda migrar al nuevo campo landingPage, ya que su ventaja es que ahora podemos indicar un sitio web con más recursos para el usuario que sólo el simple diccionario de datos.
ds:accrualPeriodicity	Frecuencia con la cual el conjunto de datos será publicado o actualizado. Los valores para este campo pueden ser "irregular" o un intervalo de repetición en ISO 8601, p. ej. "R/P1Y". Ver [1], [2], [3]

Metadatos (descriptores) del recurso o descargable (distribution)

ds:identifier	La clave que identifica al conjunto de datos al que pertenece este recurso, p. ej. "rezago-social", "unidades_médicas", "adquisiciones".
rs:title	Título descriptivo del recurso o descargable, p.ej. "Otorgamientos del 2013", "Otorgamientos del 2014", "Apoyos por municipio", "Apoyos por localidad".
rs:description	Ver ds:description. Esta explicación es adicional a la que existe en el conjunto de datos. En caso de que se requiera un diccionario de datos adicional (i.e. por recurso) se puede agregar la referencia en este espacio, p. ej. "Índice de rezago social por localidad, utilizando el catálogo de INEGI 2010. El diccionario de datos lo puedes descargar de http://web.coneval.gob.mx/Informes/Pobreza/Datos_abiertos/Pobreza %20por%20entidad%202010_DIC.txt".
rs:downloadURL	Dirección electrónica (enlace) para la descarga del recurso.
rs:mediaType	Formato de archivo del recurso a descargar, p. ej. "text/csv", "application/rss+xml". Ver [4].

³ http://en.wikipedia.org/wiki/Geography_Markup_Language

rs:byteSize	El tamaño en bytes del recurso o descargable, p. ej. 3145728
rs:temporal	Ver ds:temporal
rs:spatial	Ver ds:spatial

Notas

- En caso de necesitar diccionario de datos por recursos, agregar la liga en su campo "rs:description".
- El campo "dct:publisher" será agregado automáticamente por la herramienta ADELA, y corresponde al nombre corto de la dependencia.
- En lugar de llenar el campo "dct:license", se asume que todo lo publicado bajo datos.gob.mx está bajo los términos de libre uso del sitio en datos.gob.mx/tos.

Trabajo futuro

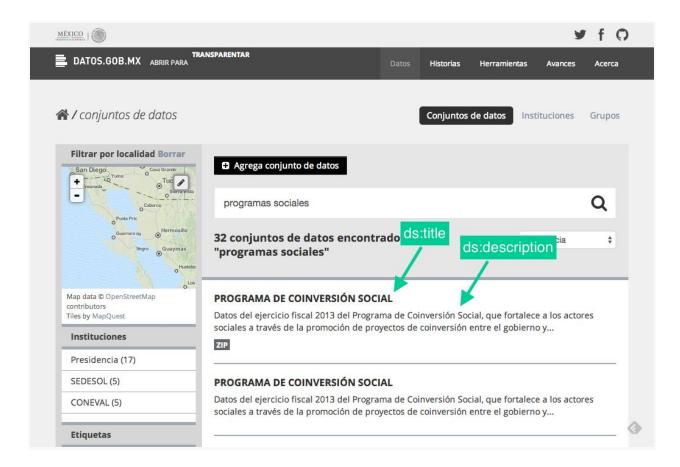
• Agregar catálogo para campos <u>dct:temporal</u>, <u>dct:spatial</u>, <u>dct:accrualPeriodicity</u>

Referencias

- [1] "Common Core Metadata Schema". Project Open Data.
- [2] "Data Catalog Vocabulary (DCAT)". W3C Recommendation 16 January 2014.
- [3] "Catálogo de Datos v2.0". DATOS.GOB.MX.
- [4] "Media Types". IANA.

Relación entre metadatos y datos.gob.mx

En el listado de resultados de búsqueda se presentan los campos de título, descripción y formatos.



En la vista de detalle del conjunto de datos se ven los campos principales del conjunto así como los campos de los recursos descargables.

